



**UNIVERSIDAD
DE ANTIOQUIA**
1 8 0 3

EXPLORACIÓN DE DATOS EEG PARA SISTEMAS BCI

Bioseñales y sistemas 2026 - 1

John Fredy Ochoa

ESTUDIANTES: Katerin Salazar Atehortua **CC:** 1007373986

Cesar Arredondo Gonzalez **CC:** 1115062806

1. Descripción del Proyecto y la Base de Datos

1.1 Contexto general

El presente proyecto tiene como objetivo central evaluar la factibilidad de construir sistemas de Interfaz Cerebro-Computador (BCI) no invasivos, utilizando señales electroencefalográficas (EEG) registradas durante tareas de movimiento real e imaginación de movimiento de las manos.

Para ello se trabaja con la base de datos pública EEG Motor Movement/Imagery Dataset, disponible en la plataforma Open Neuro.

1.2 Descripción técnica de la base de datos

Las características técnicas principales de la base de datos son las siguientes:

- **Sujetos:** 109 voluntarios sanos.
- **Canales EEG:** 64 electrodos conforme al sistema internacional 10-10 (excluyendo Nz, F9, F10, FT9, FT10, A1, A2, TP9, TP10, P9, P10).
- **Frecuencia de muestreo:** 160 Hz.
- **Formato:** EDF+ (European Data Format Plus), compatible con herramientas como MNE-Python y EEGLAB.
- **Instrumento de adquisición:** Sistema BCI2000.
- **Total de registros:** Más de 1500 grabaciones de 1 a 2 minutos de duración.
- **Licencia:** CC0 (dominio público).

1.3 Protocolo experimental

Cada sujeto realizó 14 runs experimentales, organizadas de la siguiente manera:

- **Run 1:** Línea base con ojos abiertos (1
- **Run 2:** Línea base con ojos cerrados.

- **Runs 3, 7, 11 – Tarea 1 (Movimiento real):** Aparece un objetivo en el lado izquierdo o derecho de la pantalla; el sujeto abre y cierra el puño correspondiente hasta que desaparece el objetivo, luego relaja.
- **Runs 4, 8, 12 – Tarea 2 (Imaginación de movimiento):** Igual que la Tarea 1, pero el sujeto solo imagina abrir y cerrar el puño correspondiente.
- **Runs 5, 9, 13 – Tarea 3 (Movimiento real bilateral):** El objetivo aparece arriba (ambos puños) o abajo (ambos pies); el sujeto realiza el movimiento.
- **Runs 6, 10, 14 – Tarea 4 (Imaginación bilateral):** Igual que la Tarea 3, pero imaginado.

Las anotaciones en los archivos .set siguen el esquema:

T0 = reposo.

T1 = inicio de movimiento/imaginación del puño izquierdo (o ambos puños).

T2 = inicio de movimiento/imaginación del puño derecho (o ambos pies).

Para el presente proyecto se emplean principalmente las cuatro condiciones asociadas a las tareas de mano derecha e izquierda (reales e imaginadas), correspondientes a los runs 3, 4, 7, 8, 11 y 12, además de los segmentos de reposo (T0).

El presente informe reporta el análisis estadístico de la potencia espectral EEG en los electrodos C3 y C4 durante tareas de movimiento real e imaginado de manos. Se analizaron los ritmos mu (8-13 Hz) y beta (13-30 Hz), que son las bandas de frecuencia asociadas a la actividad de la corteza motora. El objetivo es verificar la presencia de Desincronización Relacionada con Eventos (ERD) contralateral, la lateralización hemisférica, y las diferencias entre movimiento real e imaginado.

El análisis se realizó sobre 102 sujetos del dataset PhysioNet ds004362, tras excluir 7 sujetos con potencia media superior a 3 desviaciones estándar en algún canal o banda, criterio objetivo de exclusión por artefactos.

2.Marco teorico

2.1. Historia, Uso y Proyectos Futuros de la Interfaz Cerebro-Computador

2.1.1 Orígenes y evolución histórica

El concepto de BCI tiene sus raíces en la segunda mitad del siglo XX. A continuación se presenta una línea de tiempo con los hitos más relevantes:

Hito fundacional: Jacques Vidal (1973)

En 1973, el científico estadounidense Jacques Vidal, trabajando en la Universidad de California, acuñó el término "Brain-Computer Interface" en su artículo seminal "Toward Direct Brain-Computer Communication". Vidal describió el desafío BCI como el control de objetos externos usando señales EEG, y en 1977 realizó la primera demostración práctica: un sujeto humano controlando un cursor gráfico en un laberinto computacional utilizando únicamente potenciales visuales evocados (VEP). Esta demostración marcó el nacimiento formal del campo.

Décadas de 1980-1990: Primeros avances en señales y control

1988 – N. Birbaumer y colaboradores (Universidad de Tubinga): Desarrollo del concepto de control mediante potenciales corticales lentos (Slow Cortical Potentials, SCP) para comunicación en pacientes con esclerosis lateral amiotrófica (ELA). Este trabajo fundó la base del "Thought Translation Device".

1991 – J.R. Wolpaw y colaboradores (Wadsworth Center): Demostraron que los ritmos cerebrales (específicamente el ritmo sensoriomotor, SMR) podían emplearse para controlar la posición de un cursor en pantalla mediante entrenamiento de neuroretroalimentación. Este trabajo estableció el paradigma de BCI basado en ritmos sensoriomotores.

1991-1997 – G. Pfurtscheller y colaboradores (Graz University of Technology): Introdujeron y formalizaron los conceptos de Desincronización Relacionada con Eventos (ERD) y Sincronización Relacionada con Eventos (ERS) como señales de control BCI, y los aplicaron por primera vez al paradigma de imaginación de movimiento.

Década del 2000: Consolidación y sistemas de plataforma

1998 – Philip Kennedy: Implantó el primer BCI invasivo intracortical en un ser humano.

2003-2004 – BrainGate (J. Donoghue, Brown University): Primer sistema BCI invasivo implantado en un paciente tetrapléjico, permitiéndole controlar un cursor y dispositivos externos con señales neuronales directas.

2004 – BCI2000 (G. Schalk y colaboradores, Wadsworth Center): Publicación del sistema BCI2000 en IEEE Transactions on Biomedical Engineering, una plataforma de software y hardware de propósito general que estandarizó la investigación BCI a nivel mundial. Este artículo recibió el Best Paper Award de la revista IEEE TBME en 2008 y lleva más de 1,800 citas. Es también el sistema con el que se adquirió la base de datos de este proyecto.

2000-2008 – Competencias BCI (BCI Competition I-IV): Series de competencias internacionales que impulsaron el desarrollo de algoritmos de procesamiento de señales y clasificación para BCI basado en EEG, con conjuntos de datos de referencia que siguen siendo usados actualmente.

Década de 2010 en adelante: Madurez y diversificación

A partir de 2010, el campo experimentó una aceleración notable impulsada por los avances en aprendizaje profundo (deep learning), la miniaturización de hardware EEG y el creciente interés de la industria tecnológica (Google, Facebook/Meta, Neuralink) y médica.

2.2 Aplicaciones actuales de BCI

Hoy en día, los sistemas BCI se aplican en tres grandes dominios:

2.2.1. Rehabilitación y neuroprostética

- **Control de prótesis motoras:** Sistemas BCI que permiten a pacientes amputados o con lesión medular controlar brazos o piernas robóticas con señales cerebrales.
- **Neuromodulación y neuroplasticidad:** BCIs combinados con estimulación eléctrica funcional (FES) para rehabilitación post-ictus. Investigaciones recientes (Boosting BCIs with FES, Journal of NeuroEngineering and Rehabilitation, 2023) muestran que la combinación BCI-FES puede reanimar músculos paralizados mediante la detección de intención motora.
- **Recuperación del habla:** Neuroprótesis de voz que decodifican señales corticales para sintetizar habla en pacientes con parálisis severa (Littlejohn et al., Nature Neuroscience, 2025).

2.2.2 Comunicación aumentativa y alternativa

- **Síndrome de enclaustramiento (locked-in syndrome):** Sistemas que permiten comunicación mediante detección de actividad cerebral voluntaria, siendo la única vía de interacción para pacientes con esclerosis lateral amiotrófica en etapas avanzadas (Milenkovic et al., Journal of Neurophysiology).
- **Teclados y deletreadores P300:** Interfaces que detectan el componente P300 del EEG (respuesta cerebral a estímulos infrecuentes) para selección de caracteres en una matriz visual.

2.2.3. Neurociencia cognitiva y aplicaciones emergentes

- Control de videojuegos y entretenimiento.
- Monitoreo de carga cognitiva y fatiga mental en operadores (aviación, conducción).
- Neuroretroalimentación para trastornos del neurodesarrollo (TDAH, epilepsia).

2.3 Proyectos y perspectivas futuras

El campo de BCI en 2023-2025 ha alcanzado avances sin precedentes, impulsados por la convergencia de inteligencia artificial, neurociencia computacional y miniaturización de hardware:

- **Transferencia entre sujetos (Transfer Learning):** Algoritmos de aprendizaje por transferencia que permiten adaptar modelos entrenados en un sujeto para funcionar en otro sin recalibración, superando la variabilidad interindividual del EEG.
- **BCIs implantables de alta densidad:** Proyectos como Neuralink (aprobación FDA 2024 para ensayos humanos) y BrainGate buscan registrar miles de neuronas individualmente para decodificación de movimiento con alta fidelidad.
- **BCIs totalmente implantables inalámbricos:** Desarrollo de dispositivos que operan sin cables y pueden ser implantados de forma permanente, con transmisión inalámbrica de datos.
- **Integración con IA generativa:** Decodificación de lenguaje imaginado a texto con alta precisión mediante modelos de lenguaje grandes (Littlejohn et al., Nature Neuroscience, 2025).
- **BCIs no invasivos portátiles:** Gorros EEG secos de bajo costo para uso domiciliario en rehabilitación (revisión: Brain-Computer Interfaces in 2023-2024, Brain-X, Wiley, 2025).

2.4. Actividad Cerebral EEG Durante Movimiento e Imaginación de Movimiento

2.4.1 Fundamentos neurofisiológicos

El movimiento voluntario y su imaginación comparten sustratos neuronales parcialmente superpuestos en la corteza cerebral. La corteza motora primaria (M1), la corteza premotora (PM), el área motora suplementaria (SMA) y la corteza parietal posterior son las principales regiones involucradas. Durante la imaginación de movimiento (Motor Imagery, MI), no se genera salida motora real gracias a mecanismos inhibitorios en el tracto corticoespinal, pero la corteza motora y premotora sí muestran activación significativa medible con EEG.

Esta propiedad fundamental es la que hace viable el paradigma de BCI basado en MI: el sistema nervioso central genera señales eléctricas diferenciables según el tipo de movimiento imaginado, sin que el sujeto ejecute movimiento alguno.

2.4.2 Ritmos cerebrales de interés en BCI-MI

El EEG registra la actividad eléctrica sumada de millones de neuronas a través del cuero cabelludo. La señal se descompone convencionalmente en bandas de frecuencia, cada una con correlatos funcionales específicos. La siguiente tabla resume las bandas EEG y su relevancia para sistemas BCI basados en imaginación de movimiento:

Banda	Frecuencia	Estado asociado	Relevancia BCI MI
Delta	0.5 – 4 Hz	Sueño profundo, estados patológicos	Baja; indica artefactos o sueño
Theta	4 – 8 Hz	Somnolencia, memoria, creatividad	Moderada; puede reflejar carga cognitiva
Alfa (μ)	8 – 13 Hz	Relajación, ojos cerrados; ritmo mu en corteza motora	MUY ALTA: ERD/ERS del ritmo mu en C3/C4
Beta	13 – 30 Hz	Concentración, movimiento activo, estado alerta	MUY ALTA: ERD beta durante MI, ERS (rebote) post-tarea
Gamma	30 – 100 Hz	Procesamiento cognitivo complejo, percepción	Baja-moderada; difícil de separar de artefactos EMG

Para BCI-MI, las bandas de mayor relevancia son el ritmo mu (8-13 Hz, componente de la banda alfa sobre corteza sensoriomotora) y la banda beta (13-30 Hz). Ambas exhiben el fenómeno ERD/ERS durante el movimiento e imaginación de movimiento.

2.5 ERD y ERS: los fenómenos clave

Los dos mecanismos electrofisiológicos fundamentales en BCI-MI son:

2.51 Desincronización Relacionada con Eventos (ERD – Event-Related Desynchronization)

Se manifiesta como una disminución de la potencia espectral en las bandas mu y beta, localizada en la corteza sensoriomotora contralateral al miembro en movimiento (real o imaginado). Refleja el estado activo, excitado, de las neuronas corticales. Durante MI de mano derecha, se observa ERD prominente en el electrodo C3 (corteza motora izquierda), y durante MI de mano izquierda en C4. El ERD comienza típicamente 0.5-1 segundo antes del inicio del movimiento y se mantiene durante su ejecución.

Referencia: Pfurtscheller, G. & Neuper, C. (2001). Motor imagery and direct brain-computer communication. Proc. IEEE, 89(7):1123-1134.

2.5.2 Sincronización Relacionada con Eventos (ERS – Event-Related Synchronization)

Se manifiesta como un incremento de la potencia espectral, principalmente en la banda beta (13-30 Hz), observado en la región cortical ipsilateral al movimiento y/o tras la finalización del movimiento ("beta rebound"). El rebote beta post-movimiento es un marcador robusto y diferenciado que complementa la detección ERD durante el movimiento.

Referencia: Pfurtscheller, G. et al. (2006). Mu rhythm (de)synchronization and EEG single-trial classification of different motor imagery tasks. NeuroImage, 31:153-159.

La siguiente tabla presenta los electrodos de mayor relevancia para el análisis de MI de manos en este proyecto:

Electrodo	Región	Función relevante	Lateralidad MI
C3	Corteza motora izquierda	Control motor mano derecha	Ipsilateral al MI izquierdo; contralateral al derecho

C4	Corteza motora derecha	Control motor mano izquierda	Ipsilateral al MI derecho; contralateral al izquierdo
Cz	Vértex (línea media)	Control motor bilateral / miembros inferiores	Referencia central; activo en MI de pies
FC3/FC4	Fronto-centr al	Corteza premotora y motora suplementaria	Relevantes en preparación del movimiento
CP3/CP4	Centro-pariet al	Integración sensoriomotora, retroalimentación propioceptiva	Activos durante y post-MI
Fz/Pz	Frontal/Pariet al línea media	Atención, control ejecutivo, integración sensorial	Complementarios en análisis multicanal

2.5.3 Principio de lateralidad contralateral: La corteza motora de cada hemisferio controla el hemicuerpo opuesto. Por tanto, durante MI de mano derecha, el ERD máximo ocurre en C3 (hemisferio izquierdo); durante MI de mano izquierda, en C4 (hemisferio derecho). Este patrón de lateralización es el fundamento principal de los clasificadores de BCI-MI.

Estudios de referencia (Pfurtscheller et al., 2006; Lee et al., 2019 en Scientific Data PMC5493744) han demostrado consistentemente que los electrodos C3 y C4 son los más discriminativos para clasificar MI de mano izquierda vs. derecha, con el canal C4 mostrando en promedio mayor diferencia de ERD entre clases según análisis de 52 sujetos.

3. Flujos de procesamiento propuestos para el curso

Con base en la literatura científica consultada, se proponen los siguientes flujos de procesamiento, organizados de menor a mayor complejidad, y todos ejecutables con herramientas Python estándar:

3.1 Flujo A – Análisis espectral básico

1. **Carga y segmentación:** Lectura de archivos .set, extracción de épocas por condición (T0, T1, T2) con MNE-Python (`mne.read_raw_eeglab`, `mne.Epochs`).
2. **Preprocesamiento:** Filtrado pasa-banda (1-40 Hz, filtro Butterworth de orden 4), notch filter a 60 Hz, referenciado promedio (CAR – Common Average Reference).
3. **Rechazo de artefactos:** Remoción de artefactos oculares y musculares mediante Análisis de Componentes Independientes (ICA), con identificación automática de componentes o inspección manual.
4. **Extracción de características espectrales:** Estimación de la Densidad Espectral de Potencia (PSD) mediante el método de Welch para las bandas delta, theta, alfa, beta y gamma en los canales de interés (C3, C4, Cz, FC3, FC4, CP3, CP4).
5. **Construcción del data frame y análisis estadístico:** Almacenamiento de potencia por banda, canal y condición; comparación estadística entre condiciones .

3.2 Flujo B – Análisis tiempo-frecuencia

Extensión del Flujo A que incorpora representaciones tiempo-frecuencia para visualizar la dinámica temporal de ERD/ERS:

- **Transformada de Morlet (`mne.time_frequency.tfr_morlet`):** Permite calcular la potencia espectral a lo largo del tiempo con resolución conjunta tiempo-frecuencia, ideal para visualizar el ERD durante el período de MI.
- **ERSP (Event-Related Spectral Perturbation):** Potencia espectral normalizada respecto a una ventana de referencia basal (pre-estímulo), expresada como porcentaje de cambio relativo. Es la medida estándar para cuantificar ERD/ERS.

3.3 Flujo C – Extracción de características espaciales con CSP

Para grupos avanzados que deseen incluir clasificación:

- **Common Spatial Pattern (CSP):** Algoritmo de filtrado espacial óptimo que maximiza la varianza de una clase mientras minimiza la de otra. Es el método de extracción de características más citado en la literatura de BCI-MI (`sklearn.pipeline` con `mne.decoding.CSP`). Sus salida son vectores de log-varianza que alimentan clasificadores como LDA o SVM.

4. Introducción y Justificación del Plan de Análisis

El presente plan de análisis define la metodología de procesamiento y análisis de señales EEG que se aplicará al conjunto de datos, con el objetivo de evidenciar diferencias estadísticamente significativas en los ritmos cerebrales asociados a las cuatro condiciones de

estudio: (1) movimiento real de mano derecha, (2) movimiento real de mano izquierda, (3) imaginación de movimiento de mano derecha y (4) imaginación de movimiento de mano izquierda. Se incluyen además los segmentos de reposo (T0) como condición de referencia.

La justificación del plan se apoya en el fenómeno de Desincronización/Sincronización Relacionada con Eventos (ERD/ERS), ampliamente documentado en la literatura. Durante el movimiento real o imaginado de una mano, la corteza sensoriomotora contralateral exhibe una supresión del ritmo μ (8–13 Hz) y β (13–30 Hz) medible como disminución de potencia espectral (ERD). Este fenómeno es la señal biológica sobre la que se basan los sistemas BCI de imaginación de movimiento (Pfurtscheller & Neuper, 2001; Schalk et al., 2004).

Todo el pipeline está diseñado para ejecutarse en Python con bibliotecas de código abierto: MNE-Python, NumPy, SciPy, pandas y scikit-learn, siguiendo el principio de vectorización para evitar bucles innecesarios.

5. Condiciones de Estudio y Estructura de los Datos

5.1 Cuatro condiciones experimentales

El dataset contiene cuatro condiciones activas y una condición de reposo. Las condiciones activas se extraen de los **runs 3, 4, 7, 8, 11 y 12** de cada sujeto, a partir de las anotaciones T0 (reposo), T1 y T2 según el run:

Condición	Código	Descripción y Runs
Reposo	T0	Segmentos de inactividad entre tareas. Presente en todos los runs.
Mov. Real – Mano Izquierda	T1 (runs 3,7,11)	Apertura/cierre real del puño izquierdo según indicación visual.

Mov. Real – Mano Derecha	T2 (runs 3,7,11)	Apertura/cierre real del puño derecho según indicación visual.
Imaginación – Mano Izquierda	T1 (runs 4,8,12)	Imaginación de apertura/cierre del puño izquierdo sin movimiento real.
Imaginación – Mano Derecha	T2 (runs 4,8,12)	Imaginación de apertura/cierre del puño derecho sin movimiento real.

Cada sujeto aporta 3 repeticiones de 2 minutos por condición activa, lo que garantiza suficiente número de épocas para análisis estadístico robusto.

2.2 Canales de interés

De los 64 canales disponibles, el análisis se centrará en los electrodos con mayor sensibilidad a la actividad sensoriomotora de manos, basándose en la topografía funcional de la corteza motora y la literatura de BCI-MI:

- **C3 y C4** (electrodos centrales bilaterales): canales primarios de ERD contralateral. C3 refleja la actividad de la corteza motora izquierda (control de mano derecha) y C4 la derecha (control de mano izquierda).
- **Cz** (vértex, línea media): activo en movimientos bilaterales y como referencia.
- **FC3 y FC4** (fronto-centrales): corteza premotora y área motora suplementaria, relevantes en planificación del movimiento.
- **CP3 y CP4** (centro-parietales): integración sensoriomotora y retroalimentación propioceptiva.

Para el planteamiento y desarrollo de este proyecto se acotaron estos canales de interés a C3 y C4, canales clave para la elaboración de las hipótesis centradas en ERD/ERS, simplificando a su vez el manejo y volumen de datos.

6. Metodología de Procesamiento de Señal

El flujo de procesamiento sigue el pipeline estándar de BCI-MI descrito en la literatura (Lotte et al., 2018; Lee et al., 2019) y está diseñado para ser implementado como una función modular en Python que reciba un registro EEG y devuelva las características espectrales procesadas.

Paso 1 – Carga y organización de los datos

Cada archivo .set se cargará con **MNE-Python**. Se leerán las anotaciones para construir un diccionario de épocas por condición. Se verificará que los nombres de canales correspondan al montaje 10-10 y se asignará el montaje estándar para posterior visualización topográfica.

Paso 2 – Preprocesamiento

El preprocesamiento sigue cuatro subpasos secuenciales, cada uno con justificación fisiológica y técnica:

2a. Filtrado pasa-banda (7 – 35 Hz)

Se aplica un filtro de fase cero (zero-phase) Butterworth de orden 4, con frecuencia de corte inferior a 7 Hz (elimina deriva de línea base, DC offset y artefactos de movimiento de baja frecuencia) y superior a 35 Hz (elimina ruido de línea eléctrica y artefactos mioeléctricos de alta frecuencia). Se usa filtrado de fase cero para no distorsionar la relación de fase entre canales. Dado que la frecuencia de muestreo es 160 Hz (frecuencia de Nyquist = 80 Hz), este rango captura todas las bandas de interés neurofisiológico.

2b. Referenciado al promedio común (CAR)

Se aplica la referencia promedio (Common Average Reference, CAR), que resta en cada instante temporal la media de todos los canales. Esta técnica mejora la relación señal-ruido al eliminar fuentes comunes a todos los electrodos (ruido de referencia, interferencias ambientales) y realza las fuentes focales como el ERD motor. El CAR es el método de referenciado más recomendado para análisis de potencia espectral en BCI (Nunez & Srinivasan, 2006).

2c. Visualización del efecto del preprocesamiento

Para el informe se graficará la señal en dos estados: (i) señal bruta, (ii) tras filtrado, . Se usará matplotlib para segmentos representativos del canal C3, mostrando visualmente la reducción de artefactos en cada etapa.

Paso 3 – Segmentación en épocas

A partir de las anotaciones del archivo .set se extrajeron épocas de -1 a +4 segundos respecto al onset del evento. El rechazo de épocas se realizó mediante un criterio adaptativo de amplitud pico-a-pico aplicado exclusivamente sobre los electrodos C3 y C4, probando umbrales de 100, 150 y 200 μV secuencialmente hasta retener un mínimo de 5 épocas por run. Si ningún umbral preservaba ese mínimo, las épocas se aceptaban sin rechazo para evitar la exclusión total del run.

Paso 4 – Estimación de la Densidad Espectral de Potencia (PSD)

La PSD se calculará usando el método de Welch (`scipy.signal.welch`), que promedia periodogramas de segmentos solapados para reducir la varianza de la estimación. Este es el estimador espectral estándar en BCI-MI (Müller et al., 2008). Se usarán ventanas de Hann de 256 muestras (1.6 s) con 50% de solapamiento.

La potencia en cada banda de interés se calculará integrando (área bajo la curva) la PSD en el rango de frecuencias correspondiente usando la regla del trapecio (`np.trapz`), normalizada por el ancho de banda para obtener potencia media en $\mu\text{V}^2/\text{Hz}$:

7. Hipótesis del Estudio

A partir del conocimiento neurofisiológico del ERD/ERS y los patrones descritos en la literatura, se plantean las siguientes hipótesis, organizadas por fenómeno y nivel de análisis:

Hipótesis 1 – ERD contralateral del ritmo mu durante MI de manos

H₀: La potencia del ritmo mu (8–13 Hz) en C3 durante imaginación de movimiento de mano derecha es igual a la potencia durante reposo.

H₁: La potencia del ritmo mu en C3 es significativamente menor durante imaginación de movimiento de mano derecha que durante reposo (ERD contralateral).

Justificación: La contracción o imaginación de movimiento de la mano derecha activa la corteza motora izquierda (C3), generando ERD. Evidencia en: Pfurtscheller et al. (2006), NeuroImage; Lee et al. (2019), GigaScience.

Hipótesis 2 – Lateralización del ERD mu (C3 vs C4)

H₀: No existe diferencia en la potencia mu entre los electrodos C3 y C4 durante MI de mano derecha.

H₁: Durante MI de mano derecha, la potencia mu en C3 es significativamente menor que en C4 (ERD contralateral mayor en C3 que en C4).

Justificación: La lateralización es el fundamento del clasificador BCI izquierda/derecha. Una asimetría C3-C4 estadísticamente significativa valida la separabilidad de clases. Evidencia: Lee et al. (2019), PMC5493744: el canal C4 mostró mayor diferencia de ERD entre clases en 36 sujetos discriminativos.

Hipótesis 3 – Diferencia entre movimiento real e imaginado

H₀: La potencia del ritmo mu/beta en C3 durante movimiento real de mano derecha es igual a la potencia durante imaginación de movimiento de mano derecha.

H₁: Existe diferencia significativa en la potencia mu/beta entre movimiento real e imaginado (el movimiento real genera mayor ERD o en distribución topográfica diferente).

Justificación: Aunque MI activa parcialmente la corteza motora, la ejecución real involucra adicionalmente el tracto corticoespinal y retroalimentación propioceptiva. Se espera mayor ERD en real vs imaginado, aunque con patron topográfico similar (Neuper et al., 2006). Esta hipótesis permite cuantificar el grado de representación neural de la MI.

Hipótesis 4 – ERD beta y rebote post-tarea

H₀: La potencia beta en C3 durante el período de reposo post-tarea (0.5–1.5 s tras el fin de la tarea) es igual a la potencia basal pre-tarea.

H₁: La potencia beta en C3 es significativamente mayor en el período de reposo post-tarea que en el basal (rebote beta o ERS post-movimiento).

Justificación: El rebote beta post-movimiento ("beta rebound") es uno de los fenómenos EEG mejor documentados en neurofisiología motora. Confirmar su presencia en este dataset valida la calidad del pipeline y la representatividad de las señales (Pfurtscheller & Neuper, 2001).

Hipótesis 5 – Diferencia entre las cuatro condiciones activas (multiclase)

H₀: La potencia μ en C3 es igual en las cuatro condiciones activas (real derecha, real izquierda, MI derecha, MI izquierda).

H₁: Al menos una condición activa presenta potencia μ significativamente diferente en C3 respecto a las demás (análisis multiclase).

Justificación: Esta hipótesis de nivel global permite detectar que el factor 'condición' tiene efecto sobre la potencia espectral antes de analizar pares individuales, controlando la tasa de error de tipo I en comparaciones múltiples.

8. Análisis Estadístico

8.1 Estadística descriptiva

Antes de cualquier prueba inferencial, se realizó una exploración visual y descriptiva del dataset procesado. Se reportaron las estadísticas descriptivas completas (media, mediana, desviación estándar, asimetría y curtosis) por condición, canal y banda en tablas adjuntas al notebook.

Representaciones de potencia media

Barplots de potencia media por condición y banda, comparando C3 vs C4 simultáneamente con barras de error estándar. Permiten identificar visualmente el patrón de lateralización contralateral esperado (ERD en C3 para MI derecha y en C4 para MI izquierda).

Representaciones distribucionales

Violin plots por condición y canal: distribución completa de la potencia por banda y electrodo, separada por las 4 condiciones + reposo. Muestran mediana, IQR y colas de la distribución, permitiendo evaluar la asimetría de los datos y fundamentar el uso de pruebas no paramétricas.

Box plots con stripplot: comparación de C3 vs C4 en las cuatro condiciones activas. Cada punto representa una época individual, revelando outliers y la dispersión real de los datos.

Potencia media canal $\times$ banda

Heatmaps de potencia media por canal y banda para cada condición, organizados en cuadrícula (condición $\times$ banda) para comparación visual global con escala de color fija.

8.2 Verificación de supuestos estadísticos

Antes de elegir entre prueba paramétrica y no paramétrica, se verificará la normalidad de la distribución de potencia espectral para cada condición y canal:

Prueba de Shapiro-Wilk

Para cada combinación (condición $\times$ canal $\times$ banda), se aplicará `scipy.stats.shapiro()` a los valores de potencia promediados por sujeto ($n=109$ valores). Dado que la potencia espectral es inherentemente asimétrica (distribución log-normal), se espera que la mayoría de distribuciones NO sean normales, lo que orientará hacia pruebas no paramétricas.

Se verificará también la homocedasticidad (igualdad de varianzas) con la prueba de Levene (`scipy.stats.levene`) para las comparaciones entre condiciones.

8.3 Pruebas de hipótesis – Selección y justificación

Hipótesis	Comparación	Prueba	Justificación
H1, H4	Una condición vs. basal (apareado por sujeto)	Wilcoxon signed-rank test (<code>scipy.stats.wilcoxon</code>)	Comparación apareada no paramétrica; cada sujeto es su propio control. Apropiaada cuando no hay normalidad.
H2	C3 vs C4 dentro de misma condición (apareado)	Wilcoxon signed-rank test	Los dos canales se miden simultáneamente en el mismo sujeto y época.

H3	Real vs. Imaginado (apareado por sujeto)	Wilcoxon signed-rank test	Comparación apareada entre dos condiciones del mismo sujeto.
H5	Comparación de las 4+ condiciones activas	Kruskal-Wallis (scipy.stats.kruskal) + post-hoc Dunn	Extensión no paramétrica del ANOVA unidireccional. Post-hoc Dunn con corrección de Bonferroni para comparaciones múltiples (scikit_posthocs).

Si tras la verificación de supuestos se confirma normalidad ($p > 0.05$ en Shapiro-Wilk) y homocedasticidad, se podrá usar alternativamente: t de Student pareada (H1, H2, H3) y ANOVA de medidas repetidas con corrección Greenhouse-Geisser (H5).

8.4 Corrección por comparaciones múltiples

Dado que se realizaron 14 pruebas simultáneas (H1, H2, H3 y H5 sobre 2 canales $\times$ 2 bandas), se aplicó la corrección de Benjamini-Hochberg (False Discovery Rate, FDR) usando `statsmodels.stats.multitest.multipletests(method='fdr_bh')`. Este método es menos conservador que Bonferroni y más adecuado para análisis exploratorios de neuroimagen, ya que controla la proporción esperada de falsos positivos entre los resultados significativos en lugar de la probabilidad de cualquier falso positivo.


8.5 Tamaño del efecto

Para cuantificar la magnitud práctica de las diferencias encontradas, se reportó el tamaño del efecto para cada prueba:

- Para las pruebas de **Wilcoxon** signed-rank se calculó $r = Z/\sqrt{N}$, donde Z es la estandarización del estadístico W respecto a su distribución esperada bajo H_0 , y N es el número de pares (sujetos). Interpretación: $r < 0.3$ efecto pequeño, $0.3-0.5$ moderado, > 0.5 grande.
- Para **Kruskal-Wallis** se calculó $\eta^2 = (H - k + 1)/(N - k)$, donde H es el estadístico del test, k el número de grupos y N el total de observaciones. Para ANOVA se calculó $\eta^2 = (F \times (k-1)) / (F \times (k-1) + (N-k))$, donde F es el estadístico y k el número de grupos. Interpretación en ambos casos: $\eta^2 < 0.01$ efecto muy pequeño, $0.01-0.06$ pequeño, $0.06-0.14$ moderado, > 0.14 grande.

9. Diagrama Resumen del Pipeline

El siguiente esquema resume el flujo completo de procesamiento y análisis, desde los archivos .set crudos hasta las conclusiones estadísticas:



9. Criterios de Validación del Pipeline

Para garantizar la calidad del pipeline antes de correrlo sobre todos los sujetos, se realizaron las siguientes verificaciones en un sujeto piloto (sub-001). En el código final este proceso de validación no se muestra explícitamente; se documenta aquí como aclaración metodológica.

Validación del preprocesamiento

Se verificó visualmente la señal cruda vs filtrada (7–35 Hz) en el canal C3 mediante la función `graficar()`, confirmando la correcta eliminación de deriva de línea base y ruido de alta frecuencia. No se realizó validación topográfica de ritmo alpha ni verificación de componentes ICA, dado que el análisis se limita a C3 y C4 y la ICA no fue incluida en el pipeline final.

Validación de la señal ERD

Se confirmó visualmente en el sujeto piloto sub-001 que la potencia μ en C3 se reduce durante las épocas de movimiento e imaginación de mano derecha respecto al reposo, inspeccionando las distribuciones del DataFrame generado. Este es el patrón más robusto y replicado en la literatura; su ausencia indicaría un error en el pipeline. La magnitud del ERD observada fue consistente con lo reportado en la literatura: reducción de entre 16% y 20% de potencia relativa al basal en el canal contralateral (Pfurtscheller & Neuper, 2001).

Validación del DataFrame

Se verificó que el número de filas es consistente con lo esperado: para 1 sujeto $\times$ 6 runs $\times$ ~ 30 épocas por run $\times$ 5 condiciones, el DataFrame resultante contiene aproximadamente 450–600 filas. Se confirmó la ausencia de NaN en las columnas de potencia mediante `df.isnull().sum()` y que los rangos de potencia son fisiológicamente plausibles (10^{-1} a $10^3 \mu V^2/Hz$).

Referencias Bibliográficas

Todas las fuentes a continuación son publicaciones científicas revisadas por pares (peer-reviewed) o bases de datos abiertas de acceso público:

Base de datos y sistema de adquisición

- [1] Schalk, G., McFarland, D.J., Hinterberger, T., Birbaumer, N., Wolpaw, J.R. (2004). BCI2000: A General-Purpose Brain-Computer Interface (BCI) System. *IEEE Transactions on Biomedical Engineering*, 51(6):1034-1043. DOI: 10.1109/TBME.2004.827072 [Best Paper Award IEEE TBME 2008].
- [2] Goldberger, A.L. et al. (2000). PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals. *Circulation*, 101(23):e215-e220.
- [3] OpenNeuro Dataset ds004362 v1.0.0. DOI: 10.18112/openneuro.ds004362.v1.0.0. Disponible en: <https://openneuro.org/datasets/ds004362/versions/1.0.0>

Historia y revisiones de BCI

- [4] Vidal, J.J. (1973). Toward direct brain-computer communication. *Annual Review of Biophysics and Bioengineering*, 2:157-180. DOI: 10.1146/annurev.bb.02.060173.001105
- [5] Wolpaw, J.R., Birbaumer, N., McFarland, D.J., Pfurtscheller, G., Vaughan, T.M. (2002). Brain-computer interfaces for communication and control. *Clinical Neurophysiology*, 113(6):767-791.
- [6] Brunner, C. et al. (2021). Summary of over Fifty Years with Brain-Computer Interfaces — A Review. *Brain Sciences*, 11(1):43. DOI: 10.3390/brainsci11010043

- [7] Värbu, K., Muhammad, N., Muhammad, Y. (2022). Past, Present, and Future of EEG-Based BCI Applications. *Sensors*, 22(9):3331. DOI: 10.3390/s22093331
- [8] Xu, X. et al. (2025). Brain-Computer Interfaces in 2023-2024. *Brain-X* (Wiley). DOI: 10.1002/brx2.70024

Neurofisiología de la imaginación de movimiento y ERD/ERS

- [9] Pfurtscheller, G. & Neuper, C. (2001). Motor imagery and direct brain-computer communication. *Proceedings of the IEEE*, 89(7):1123-1134.
- [10] Pfurtscheller, G. et al. (2006). Mu rhythm (de)synchronization and EEG single-trial classification of different motor imagery tasks. *NeuroImage*, 31:153-159. DOI: 10.1016/j.neuroimage.2005.12.003
- [11] Neuper, C. et al. (2006). Motor imagery and EEG-based control of spelling devices and neuroprostheses. *Progress in Brain Research*, 159:393-409.
- [12] Chen, X. et al. (2025). A multi-day and high-quality EEG dataset for motor imagery brain-computer interface. *Scientific Data* (Nature). DOI: 10.1038/s41597-025-04826-y

Flujos de procesamiento y análisis

- [13] Lee, M.H. et al. (2019). EEG datasets for motor imagery brain-computer interface. *GigaScience*, 8(5). PMC ID: PMC5493744. DOI: 10.1093/gigascience/giz002
- [14] Lotte, F. et al. (2018). A review of classification algorithms for EEG-based brain-computer interfaces: A 10 year update. *Journal of Neural Engineering*, 15(3):031005.
- [15] Saha, S. & Baumert, M. (2020). Intra- and Inter-subject Variability in EEG-Based Sensorimotor Brain Computer Interface: A Review. *Frontiers in Computational Neuroscience*, 13:87.
- [16] Arvaneh, M. et al. (2022). EEG feature extraction methods in motor imagery-based brain-computer interfaces: a systematic review and network meta-analysis. *Expert Review of Medical Devices*, 2025. DOI: 10.1080/27706710.2025.2523303

Aplicaciones clínicas y futuro de BCI

- [17] Canny, E. & Berezutskaya, J. (2023). Boosting brain-computer interfaces with functional electrical stimulation: potential applications in people with locked-in syndrome. *Journal of NeuroEngineering and Rehabilitation*, 20:157. DOI: 10.1186/s12984-023-01272-y
- [18] Littlejohn, K.T. et al. (2025). A streaming brain-to-voice neuroprosthesis to restore naturalistic communication. *Nature Neuroscience*, 28(4):902-912. DOI: 10.1038/s41593-025
- [19] Frontiers Research Topic (2024). Brain-Computer Interfaces in Neurological Disorders: Expanding Horizons for Diagnosis, Treatment, and Rehabilitation. *Frontiers in Human Neuroscience*.

Bandas de frecuencia EEG

- [20] Newson, J.J. & Thiagarajan, T.C. (2018). EEG Frequency Bands in Psychiatric Disorders: A Review of Resting State Studies. *Frontiers in Human Neuroscience*, 12:521. DOI: 10.3389/fnhum.2018.00521
- [21] PMC Review (2022). Review of electroencephalography signals approaches for mental stress assessment. PMC9749579.