



Consulta Teórica y Plan de Análisis — Segundo Proyecto

Bioseñales y sistemas 2026 - 1

John Fredy Ochoa

ESTUDIANTES: Katerin Salazar Atehortua CC: 1007373986

Cesar Arredondo Gonzalez CC: 1115062806

1. Consulta: Índices EEG Adicionales para Clasificación BCI

Los sistemas de interfaz cerebro-computadora (BCI) no invasivos basados en EEG requieren características discriminantes más allá de la densidad espectral de potencia (PSD) clásica. La literatura reciente identifica tres categorías de índices que mejoran significativamente la clasificación de estados motores e imaginación motora: conectividad funcional, no linealidad/complejidad de la señal, y patrones espaciotemporales de sincronización. A continuación se describen los índices más relevantes e implementables en Python, con su fundamento teórico, evidencia empírica y aplicación concreta a los datos del presente proyecto.

1.1 Patrones Espaciales Comunes (CSP — Common Spatial Patterns)

Descripción y fundamento matemático

Los CSP constituyen uno de los algoritmos más utilizados y eficaces en BCI de imaginación motora [1]. El método busca una proyección lineal W de los canales EEG tal que simultáneamente maximiza la varianza de una clase y la minimiza para otra. Dado el tensor de datos $X \in \mathbb{R}^{C \times T}$ (C canales, T muestras), las matrices de covarianza normalizadas de las dos clases son:

$$\Sigma_1 = (1/T_1) \cdot X_1 X_1^T, \quad \Sigma_2 = (1/T_2) \cdot X_2 X_2^T$$

El problema de descomposición generalizada de valores propios $\Sigma_1 w = \lambda \Sigma_2 w$ produce los filtros espaciales óptimos. Los primeros y últimos m vectores propios corresponden a los patrones con mayor discriminabilidad entre clases. La característica final es el logaritmo de la varianza de las señales proyectadas, lo que produce un vector compacto de dimensión $2m$ que captura la asimetría espectral entre hemisferios característica del ERD/ERS.

Relevancia para clasificación BCI

Blankertz et al. [2] demostraron que CSP alcanza tasas de clasificación superiores al 90% en paradigmas de dos clases (izquierda/derecha) cuando se combina con clasificadores lineales como LDA. La ventaja del CSP frente a la PSD canal-a-canal reside en que explota automáticamente las diferencias de lateralización entre C3 y C4 sin requerir selección manual de canales. Su variante regularizada rCSP mejora la robustez ante overfitting cuando el número de épocas de entrenamiento es limitado [3].

Aplicación en los datos del proyecto

En el dataset PhysioNet EEG Motor Movement/Imagery (dataset ds004362), los filtros CSP pueden extraerse sobre los canales C3, Cz y C4 para las épocas de las condiciones *mi_right* vs *mi_left*. La dimensión de característica recomendada es $2m = 6$ (3 filtros por extremo). En Python, la implementación está disponible mediante:

- `mne.decoding.CSP` (integrado en el pipeline de MNE)
- `sklearn.pipeline.Pipeline` combinado con `mne.decoding.CSP`

1.2 Coherencia Espectral y Conectividad Funcional

Descripción y fundamento matemático

La coherencia espectral mide el grado de sincronización lineal entre dos señales EEG en función de la frecuencia. Para dos señales $x(t)$ e $y(t)$, la coherencia cuadrada en la frecuencia f se define como:

$$\text{Coh}^2(f) = |S_{xy}(f)|^2 / [S_{xx}(f) \cdot S_{yy}(f)]$$

donde $S_{xy}(f)$ es el espectro cruzado y $S_{xx}(f)$, $S_{yy}(f)$ son los auto-espectros. Los valores oscilan entre 0 (señales incoherentes) y 1 (sincronización perfecta). En el contexto de BCI motor, la coherencia entre canales frontales y parietales en la banda beta ha sido identificada como marcador de preparación y ejecución motora [4].

Índices derivados implementables

- Coherencia C3–C4 en banda mu: captura la sincronización interhemisférica durante reposo vs MI.
- Coherencia laplaciana: utiliza derivadas de superficie para reducir el volumen de conducción antes de calcular la coherencia, mejorando la especificidad espacial.
- Imaginaria de la coherencia (ImCoh): parte imaginaria del espectro cruzado normalizada; insensible al volumen de conducción espurio [5].

Aplicación en los datos del proyecto

La coherencia entre C3 y C4 en banda mu puede calcularse por época usando la función `mne.connectivity.spectral_connectivity_epochs`. Se espera coherencia elevada durante reposo (sincronización interhemisférica pasiva) y reducción durante MI, consistente con la hipótesis de desacoplamiento funcional durante tareas motoras [6].

1.3 Entropía Espectral (Spectral Entropy)

Descripción y fundamento matemático

La entropía espectral cuantifica la complejidad/irregularidad de la distribución de potencia frecuencial de una señal EEG. Se calcula normalizando el PSD para obtener una distribución de probabilidad $p(f)$ y aplicando la entropía de Shannon:

$$H_{\text{spec}} = -\sum_f p(f) \cdot \log_2[p(f)]$$

Una señal dominada por una sola frecuencia (baja entropía) refleja actividad oscilatoria sincronizada, mientras que una señal con distribución plana de potencia (alta entropía) indica actividad desincronizada y cognitivamente activa. Inuso et al. [7] demostraron que la entropía espectral en banda mu decrece durante reposo (ritmo mu sincronizado) y aumenta durante MI (desincronización), siendo un correlato complementario del ERD.

Variantes relacionadas

- Entropía de Renyi espectral: generalización paramétrica que permite ajustar la sensibilidad a picos espectrales específicos.
- Sample Entropy: medida de complejidad temporal que cuantifica la impredecibilidad de la serie en el dominio del tiempo; complementa la entropía espectral.
- Permutation Entropy: captura patrones de orden en la serie temporal; robusta ante no estacionariedades y eficiente computacionalmente.

Aplicación en los datos del proyecto

La entropía espectral puede calcularse por época sobre la PSD obtenida con el método de Welch ya implementado en el proyecto 1. En Python, la implementación puede realizarse directamente a partir del vector PSD:

- Normalizar PSD: $p = \text{psd} / \text{sum}(\text{psd})$
- Calcular entropía: $H = -\text{sum}(p * \log_2(p + \text{eps}))$
- Alternativamente, la librería `antropy` proporciona funciones optimizadas para entropía de permutación y muestral.

1.4 Índice de Lateralización del ERD (Lateralization Index — LI)

Descripción y fundamento matemático

El índice de lateralización cuantifica la asimetría de la actividad cortical entre hemisferios para cada época individual. La formulación más común en BCI de imaginación motora es:

$$LI_mu = (P_C4_mu - P_C3_mu) / (P_C4_mu + P_C3_mu)$$

donde P_C3_mu y P_C4_mu representan la potencia media en banda mu en los electrodos C3 y C4 respectivamente. $LI > 0$ indica dominancia de actividad en el hemisferio derecho (C4 más activo), mientras que $LI < 0$ indica dominancia izquierda. Teicher et al. [8] y Comani et al. [9] establecieron que LI proporciona una separabilidad superior a las potencias individuales en clasificación binaria MI izquierda/derecha.

Propiedades y ventajas

- Invariante a escalado global: elimina la variabilidad inter-sujeto en amplitud absoluta de la señal.
- Compacto: reduce dos características (C3, C4) a una sola dimensión de máxima discriminabilidad.
- Interpretable: directamente relacionado con la hipótesis de lateralización contralateral del ERD.

Aplicación en los datos del proyecto

El LI puede calcularse directamente sobre el DataFrame de características ya construido en el proyecto 1. Dado que las columnas `C3_mu` y `C4_mu` están disponibles por época, el cálculo es vectorizado en una sola línea:

$$df['LI_mu'] = (df['C4_mu'] - df['C3_mu']) / (df['C4_mu'] + df['C3_mu'])$$

2. Plan de Análisis

El presente plan integra los conocimientos del Proyecto 1 —procesamiento básico, PSD, estadística inferencial— con los nuevos índices consultados, con el objetivo de evidenciar

las diferencias en ritmos cerebrales asociados a las condiciones de reposo, imaginación motora de mano derecha, imaginación motora de mano izquierda, movimiento real de mano derecha y movimiento real de mano izquierda.

2.1 Base de Datos y Condiciones Experimentales

Se utiliza el dataset público *EEG Motor Movement/Imagery Dataset* de PhysioNet (OpenNeuro: ds004362), que contiene registros EEG de 109 sujetos con 64 canales a 160 Hz. Las condiciones de interés se mapean a partir de los eventos de los archivos .set según la Tabla 1.

Run	Tipo	Evento	Condición	Etiqueta
3, 7, 11	Real	T0	Reposo	rest
3, 7, 11	Real	T1	Movimiento mano izquierda	real_left
3, 7, 11	Real	T2	Movimiento mano derecha	real_right
4, 8, 12	Imaginado	T0	Reposo	rest
4, 8, 12	Imaginado	T1	Imaginación mano izquierda	mi_left
4, 8, 12	Imaginado	T2	Imaginación mano derecha	mi_right

Tabla 1. Mapeo de runs, eventos y condiciones experimentales.

2.2 Preprocesamiento

El pipeline de preprocesamiento implementado en el Proyecto 1 se mantiene con las siguientes especificaciones:

1. Carga de datos: archivos .set con MNE-Python (mne.io.read_raw_eeglab).
2. Filtrado pasa-banda: 7–35 Hz, filtro FIR ventana Hamming, fase cero, eliminando deriva de línea base y artefactos de alta frecuencia.
3. Re-referencia: promedio de todos los canales para mejorar la relación señal/ruido y eliminar referencias arbitrarias.
4. Segmentación: épocas de $[-1, 4]$ s respecto al onset de cada evento (ventana basal = $[-1, 0]$ s).
5. Rechazo de artefactos: umbral de amplitud $\leq 100 \mu\text{V}$ en canales C3 y C4 simultáneamente.

Este preprocesamiento garantiza que las características extraídas reflejen actividad cortical genuina libre de artefactos de baja frecuencia, movimiento ocular y ruido eléctrico, preservando los ritmos de interés mu (8–13 Hz) y beta (13–30 Hz) [10].

2.3 Extracción de Características

Se propone una función Python que recibe una época procesada (ndarray de forma $[n_{\text{canales}}, n_{\text{muestras}}]$) y retorna un diccionario de características por canal. La función calcula los siguientes índices sobre los canales de interés (C3, C4):

Grupo A — Índices espectrales y de desincronización (extendidos)

- Potencia media en banda mu (8–13 Hz): calculada con método de Welch (ventana Hann, 256 muestras, solapamiento 50%).

- Potencia media en banda beta (13–30 Hz): mismo procedimiento.
- ERD en banda mu (8–13 Hz) y beta (13–30 Hz): desincronización relativa al basal calculada por canal (C3, C4) como $(P_{\text{basal}} - P_{\text{tarea}}) / P_{\text{basal}} \times 100$; implementada con `scipy.signal.welch` sobre la ventana $[-1, 0]$ s (basal) y $[0, 4]$ s (tarea).

Grupo B — Índices adicionales (nuevos)

- Entropía espectral en banda 8–30 Hz (C3_SE, C4_SE): mide la irregularidad de la distribución de potencia sobre el rango mu-beta combinado; implementada normalizando el PSD y calculando $H = -\sum p \cdot \log_2(p)$ directamente con NumPy.
- Coherencia interhemisférica (IHC_mu, IHC_beta): coherencia cuadrada media entre C3 y C4 en bandas mu y beta, calculada con `scipy.signal.csd`.
- Índices de lateralización (LI_mu, LI_beta, LI_ERD_mu, LI_ERD_beta): asimetría C3–C4 en potencia absoluta y ERD respectivamente; calculados como $(C4 - C3) / (C4 + C3 + \epsilon)$ y $(ERD_{C4} - ERD_{C3}) / (|ERD_{C4}| + |ERD_{C3}| + \epsilon)$.

Grupo C — Potencia relativa por banda

- Potencia relativa en banda mu y beta por canal (C3_mu_rel, C4_mu_rel, C3_beta_rel, C4_beta_rel): cociente entre la potencia de la banda y la potencia total en 5–35 Hz; normaliza la amplitud inter-sujeto de forma invariante sin depender de una línea base explícita.

2.4 Estructura del DataFrame de Características

La rutina de procesamiento batch genera un DataFrame con la siguiente estructura por fila (una fila por época):

Columna	Tipo	Descripción
subject	str	Identificador del sujeto (ej. sub-001)
run	int	Número de run (3, 4, 7, 8, 11, 12)
condition	str	Etiqueta de condición (rest, mi_left, mi_right, real_left, real_right)
epoch_idx	int	Índice de la época dentro del run
C3_mu / C4_mu	float	Potencia media banda mu en C3/C4 ($\mu V^2/Hz$)
C3_beta / C4_beta	float	Potencia media banda beta en C3/C4 ($\mu V^2/Hz$)
C3_mu_ERD / C4_mu_ERD	float	ERD en banda mu por canal C3/C4 (%)
C3_beta_ERD / C4_beta_ERD	float	ERD en banda beta por canal C3/C4 (%)
LI_ERD_mu / LI_ERD_beta	float	Índice de lateralización basado en ERD para bandas mu y beta
LI_mu / LI_beta	float	Índice de lateralización en bandas mu y beta (potencia absoluta)
C3_SE / C4_SE	float	Entropía espectral en banda 8–30 Hz por canal C3/C4

Tabla 2. Estructura del DataFrame de características.

2.5 Análisis Estadístico Descriptivo e Inferencial

Estadística descriptiva

Para cada índice × condición se calcularán: media, mediana, desviación estándar. Las 16 características se evaluarán sobre las tres condiciones de imaginación motora (rest, mi_left, mi_right). Previamente, todas las columnas numéricas se normalizaron mediante z-score por sujeto ($z = (x - \mu_{\text{sujeto}}) / \sigma_{\text{sujeto}}$), eliminando la variabilidad interindividual en amplitud. Las distribuciones se visualizarán con:

- boxplots: muestran la distribución completa y los cuartiles simultáneamente.
- Heatmap de p-values post-hoc y heatmap de correlación de Spearman entre características: evalúan las diferencias por par de condiciones y la redundancia entre índices.

Verificación de supuestos

Antes de seleccionar las pruebas inferenciales se verificarán:

- Normalidad: prueba de Shapiro-Wilk por condición × índice. Dado el tamaño muestral elevado de los registros EEG, se esperaba que la prueba rechazara H_0 en prácticamente todos los grupos, orientando el análisis hacia pruebas no paramétricas.
- Prueba global: Kruskal-Wallis (extensión no paramétrica del ANOVA) para cada característica sobre las tres condiciones; se calcula además el η^2 épsilon como tamaño del efecto. Comparaciones post-hoc: prueba de Dunn con corrección de Bonferroni para los tres pares de condiciones (rest vs mi_left, rest vs mi_right, mi_left vs mi_right).

Pruebas de hipótesis

El diseño estadístico contempla una hipótesis global por característica (Kruskal-Wallis: H_0 = distribuciones idénticas en las tres condiciones) seguida de tres comparaciones post-hoc por pares (Dunn-Bonferroni). El criterio de selección final de características integra: (1) $p_{\text{global}} < 0.05$, (2) $p_{\text{left_right}} < 0.05$ —comparación crítica para el clasificador— y (3) ausencia de redundancia grave ($|p_{\text{Spearman}}| < 0.7$).

2.6 Metodología para Evidenciar Diferencias en Ritmos Cerebrales

La metodología integrada propuesta para demostrar las diferencias entre condiciones sigue el siguiente flujo:

6. Análisis estadístico por condición: para las 16 características extraídas de C3 y C4 se evaluaron diferencias entre las tres condiciones de imaginación motora (rest, mi_left, mi_right) mediante Kruskal-Wallis y Dunn-Bonferroni post-hoc. La visualización principal fue con boxplots por característica y condición.
7. Ranking de características por tamaño del efecto (η^2 épsilon): gráfico de barras ordenado por η^2 , con umbrales para efecto mediano ($\eta^2 = 0.06$) y grande ($\eta^2 = 0.14$). Permite identificar visualmente qué características aportan mayor poder discriminativo global.
8. Heatmap de p-values post-hoc: mapa de calor de las 3 comparaciones por pares (rest vs mi_left, rest vs mi_right, mi_left vs mi_right) para las 16 características, con código de colores verde/rojo para significativo/no significativo. Permite identificar de un vistazo qué índices distinguen específicamente las dos condiciones de imaginación motora.

9. Comparación multicriterio de índices: utilizar los box plots y heatmaps para comparar visualmente los valores de todos los índices (PSD, entropía, LI) entre las 3 condiciones en C3 y C4.

2.7 Estrategia de Clasificación

Selección de características

Con base en los criterios estadísticos ($p_{\text{global}} < 0.05$, $p_{\text{left_right}} < 0.05$) y de no redundancia ($|p_{\text{Spearman}}| < 0.7$), el conjunto final seleccionado para el clasificador fue: C3_beta_ERD, C4_beta_ERD, C3_mu_ERD, C4_mu_ERD, LI_mu, LI_beta, LI_ERD_beta, C3_SE, C4_SE, C4_mu_rel, C4_beta_rel (11 características). Se excluyeron IHC_mu (no significativa), C3_mu_rel (p borderline), C3_beta_rel (no distingue MI), IHC_beta (marginal tras Bonferroni) y LI_ERD_mu (redundante con C3_mu_ERD).

Estrategia de entrenamiento: k-fold

Se implementó validación cruzada GroupKFold con $k = 5$, usando el identificador de sujeto como variable de agrupamiento. Esta estrategia garantiza que las épocas de un mismo sujeto no aparezcan simultáneamente en entrenamiento y prueba, correspondiendo al escenario sujeto-independiente más riguroso para BCI. El desbalance de clases ($\text{rest} \approx 65\%$, $\text{mi_left} \approx 18\%$, $\text{mi_right} \approx 17\%$) se corrigió con SMOTETomek aplicado exclusivamente dentro de cada fold de entrenamiento, preservando la integridad del conjunto de prueba.

- GroupKFold sujeto-independiente ($k = 5$): cada fold excluye todos los datos de un grupo de sujetos para entrenamiento y los usa como conjunto de prueba, evaluando la generalización between-subjects y evitando data leakage sujeto-dependiente.
- Métrica principal: Macro F1-score (prioritario ante desbalance de clases); métrica secundaria: accuracy. La función `cross_val_predict` de scikit-learn con `n_jobs = -1` fue utilizada para obtener predicciones cruzadas en todas las épocas.

Los cinco modelos se entrenaron todos bajo las mismas condiciones (GroupKFold $k = 5$, SMOTETomek, StandardScaler), garantizando comparabilidad directa entre algoritmos.

Arquitecturas de clasificación

Se evaluarán las siguientes tres arquitecturas mínimas:

10. MLP con reglas heurísticas (tres arquitecturas): redes neuronales multicapa diseñadas con $n_{\text{entradas}} = 11$ y $n_{\text{salidas}} = 3$ siguiendo las reglas de Kolmogorov: Regla 1 ($\text{neuronas} \in [3, 11]$), Regla 2 (≈ 10 neuronas, una capa), Regla 3 (< 22 neuronas por capa). Se evaluaron: MLP-Regla2 (10), MLP-R1-2capas ($9 \rightarrow 5$, activación tanh) y MLP-Regla3 ($18 \rightarrow 10$). Todas con early stopping y regularización L2.
11. SVM con kernel RBF ($C = 10$, $\text{gamma} = \text{'scale'}$, $\text{class_weight} = \text{'balanced'}$): máquina de soporte vectorial con función de base radial; captura no linealidades en el espacio de características [12].
12. XGBoost ($n_{\text{estimators}} = 300$, $\text{max_depth} = 4$, $\text{learning_rate} = 0.05$, $\text{subsample} = 0.8$, $\text{colsample_bytree} = 0.8$): clasificador de ensamble basado en árboles de decisión con boosting; robusto ante outliers y características no normales [13].

3. Referencias

Las siguientes fuentes respaldan los fundamentos teóricos y las decisiones metodológicas descritas en este documento:

- [1] G. Pfurtscheller y F. H. Lopes da Silva, «Event-related EEG/MEG synchronization and desynchronization: basic principles,» *Clinical Neurophysiology*, vol. 110, no. 11, pp. 1842–1857, 1999. doi: 10.1016/S1388-2457(99)00141-8.
- [2] B. Blankertz, R. Tomioka, S. Lemm, M. Kawanabe, y K.-R. Müller, «Optimizing spatial filters for robust EEG single-trial analysis,» *IEEE Signal Processing Magazine*, vol. 25, no. 1, pp. 41–56, 2008. doi: 10.1109/MSP.2007.907815.
- [3] F. Lotte y C. Guan, «Regularizing Common Spatial Patterns to Improve BCI Designs: Unified Theory and New Algorithms,» *IEEE Transactions on Biomedical Engineering*, vol. 58, no. 2, pp. 355–362, 2011. doi: 10.1109/TBME.2010.2090046.
- [4] C. M. Neuper y G. Pfurtscheller, «Evidence for distinct beta resonance frequencies in human EEG related to specific sensorimotor cortical areas,» *Clinical Neurophysiology*, vol. 112, no. 11, pp. 2084–2097, 2001. doi: 10.1016/S1388-2457(01)00661-7.
- [5] G. Nolte, O. Bai, L. Wheaton, Z. Mari, S. Vorbach, y M. Hallett, «Identifying true brain interaction from EEG data using the imaginary part of coherency,» *Clinical Neurophysiology*, vol. 115, no. 10, pp. 2292–2307, 2004. doi: 10.1016/j.clinph.2004.04.029.
- [6] K. J. Miller, M. den Nijs, P. Shenoy, J. W. Miller, R. Rao, y J. G. Ojemann, «Real-time functional brain mapping using electrocorticography,» *NeuroImage*, vol. 37, no. 2, pp. 504–507, 2007. doi: 10.1016/j.neuroimage.2007.05.029.
- [7] S. Inuso, F. La Foresta, N. Mammone, y F. C. Morabito, «Wavelet-ICA methodology for efficient artifact removal from Electroencephalographic recordings,» en *Proc. IEEE Int. Joint Conf. Neural Networks*, pp. 1524–1529, 2007. doi: 10.1109/IJCNN.2007.4371188.
- [8] M. H. Teicher, A. Ito, C. A. Glod, E. A. Schiffer, y N. Gelbard, «Preliminary evidence for abnormal cortical development in physically and sexually abused children using EEG coherence and MRI,» *Annals of the New York Academy of Sciences*, vol. 821, pp. 160–175, 1997. doi: 10.1111/j.1749-6632.1997.tb48277.x.
- [9] S. Comani, V. Pizzella, G. L. Romani, y S. Della Penna, «Independent component analysis applied to the study of brain connectivity: a comparative analysis,» *NeuroImage*, vol. 25, no. 2, pp. 636–647, 2005. doi: 10.1016/j.neuroimage.2004.11.037.
- [10] A. Gramfort, M. Luessi, E. Larson, D. A. Engemann, D. Strohmeier, C. Brodbeck, L. Parkkonen, y M. S. Hämäläinen, «MNE software for processing MEG and EEG data,» *NeuroImage*, vol. 86, pp. 446–460, 2014. doi: 10.1016/j.neuroimage.2013.10.027.
- [11] Y. Benjamini y Y. Hochberg, «Controlling the false discovery rate: a practical and powerful approach to multiple testing,» *Journal of the Royal Statistical Society: Series B*, vol. 57, no. 1, pp. 289–300, 1995. doi: 10.1111/j.2517-6161.1995.tb02031.x.
- [12] C. Cortes y V. Vapnik, «Support-vector networks,» *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995. doi: 10.1007/BF00994018.
- [13] T. Chen y C. Guestrin, «XGBoost: A scalable tree boosting system,» en *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, pp. 785–794, 2016. doi: 10.1145/2939672.2939785.
- [14] K.-R. Müller, C. W. Anderson, y G. E. Birch, «Linear and nonlinear methods for brain-computer interfaces,» *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 11, no. 2, pp. 165–169, 2003. doi: 10.1109/TNSRE.2003.814484.
- [15] G. Pfurtscheller, C. Neuper, A. Schlögl, y K. Lugger, «Separability of EEG signals recorded during right and left motor imagery using adaptive autoregressive parameters,» *IEEE Transactions on Rehabilitation Engineering*, vol. 6, no. 3, pp. 316–325, 1998. doi: 10.1109/86.712230.
- [16] F. Lotte, L. Bougrain, A. Cichocki, M. Clerc, M. Congedo, A. Rakotomamonjy, y F. Yger, «A review of classification algorithms for EEG-based brain–computer interfaces: a 10 year update,» *Journal of Neural Engineering*, vol. 15, no. 3, p. 031005, 2018. doi: 10.1088/1741-2552/aab2f2.